

COMPUTAÇÃO EM NUVEM

DOCENTE:
Tarcisio da Rocha

DISCENTES:

Davi Costa,
Pedro Thalles

MÓDULO 1

- Amazon EC2;
- Amazon EBS;
- EC2 Auto Scaling;
- AWS Systems Manager;
- AWS CloudFormation;

EC2:

O Amazon EC2 é o serviço de servidores virtuais da AWS, permite provisionar capacidade computacional sob demanda na nuvem, sem a necessidade de comprar e manter hardware físico.

Quando uma instância é lançada, o tipo de instância determina o hardware do host usado, ou seja, a combinação de vCPUs, memória, armazenamento e capacidade de rede disponível.

EC2 TIPOS DE INSTÂNCIA:

- **Uso geral:** Oferecem equilíbrio entre computação, memória e rede. Indicadas para servidores web, repositórios de código e bancos de dados pequenos/médios. Ex: famílias T, M. (Curiosidade: a família T pode exceder o uso de CPU ao qual foi alocado conforme a necessidade e os créditos disponíveis).

- **Otimizadas para computação:** Voltadas a cargas que exigem alto poder de processamento: processamento em lote, transcodificação de mídia, servidores web de alta performance, modelagem científica, computação de alto desempenho e inferência de machine learning. Ex.: família C.

EC2 TIPOS DE INSTÂNCIA:

- **Otimizadas para memória:** Projetadas para cargas que processam grandes conjuntos de dados em memória, como bancos de dados in-memory e cache de grande escala. Ex: famílias R, X.

- **Otimizadas para armazenamento:** Voltadas a cargas que exigem acesso sequencial de alto rendimento a grandes volumes de dados locais, entregando dezenas de milhares de IOPS (Operações de Entrada/Saída por Segundo) com baixa latência. Ex: famílias I, D, H.

EC2 TIPOS DE INSTÂNCIA:

- **Computação acelerada:** Usam aceleradores de hardware (GPUs, chips dedicados) para tarefas como cálculo de ponto flutuante, processamento gráfico e reconhecimento de padrões — comuns em IA/ML. Ex: famílias P, G, Inf.

Todos os tipos de instância:

Amazon EC2 supports the following hypervisors: Xen and Nitro.

Nitro-based instances

- **General purpose:** M5 | M5a | M5ad | M5d | M5dn | M5n | M5zn | M6a | M6g | M6gd | M6i | M6id | M6idn | M6in | M7a | M7g | M7gd | M7i | M7i-flex | M8a | M8azn | M8g | M8gb | M8gd | M8gn | M8i | M8id | M8i-flex | M8in | M8idn | M8ine | M8ib | M8idb | M9g | M9gd | T3 | T3a | T4g | T8i
- **Compute optimized:** C5 | C5a | C5ad | C5d | C5n | C6a | C6g | C6gd | C6gn | C6i | C6id | C6in | C7a | C7g | C7gd | C7gn | C7i | C7i-flex | C8a | C8g | C8gb | C8gd | C8gn | C8i | C8id | C8i-flex | C8in | C8ine | C8ib | C9g | C9gd
- **Memory optimized:** R5 | R5a | R5ad | R5b | R5d | R5dn | R5n | R6a | R6g | R6gd | R6i | R6id | R6idn | R6in | R7a | R7g | R7gd | R7i | R7iz | R8a | R8g | R8gb | R8gd | R8gn | R8i | R8id | R8i-flex | R8in | R8idn | R8ib | R8idb | R9g | R9gd | U-3tb1 | U-6tb1 | U-9tb1 | U-12tb1 | U-18tb1 | U-24tb1 | U7i-6tb | U7i-8tb | U7i-12tb | U7in-16tb | U7in-24tb | U7in-32tb | U7inh-32tb | X2gd | X2idn | X2iedn | X2iezn | X8g | X8aedz | X8i | z1d
- **Storage optimized:** D3 | D3en | I3en | I4g | I4i | I7i | I7ie | I8g | I8ge | Im4gn | Is4gen
- **Accelerated computing:** DL1 | DL2q | F2 | G4ad | G4dn | G5 | G5g | G6 | G6e | G6f | Gr6 | Gr6f | G7 | G7e | Inf1 | Inf2 | P4d | P4de | P5 | P5e | P5en | P6-B200 | P6-B300 | P6e-GB200 | Trn1 | Trn1n | Trn2 | Trn2u | VT1
- **High-performance computing:** Hpc6a | Hpc6id | Hpc7a | Hpc7g | Hpc8a
- **Previous generation:** A1 | P3dn

For more information about the supported versions of Nitro hypervisor, see Network feature support in the *Amazon EC2 Instance Types Guide*.

Xen-based instances

- **General purpose**: M1 | M2 | M3 | M4 | T1 | T2
- **Compute optimized**: C1 | C3 | C4
- **Memory optimized**: R3 | R4 | X1 | X1e
- **Storage optimized**: D2 | H1 | I2 | I3
- **Accelerated computing**: G3 | P3

. As instâncias baseadas em Xen usam um hipervisor tradicional baseado em software que consome parte da CPU e da memória do host para gerenciar essas tarefas, já as instâncias baseadas no AWS Nitro System descarregam essas funções para placas de hardware dedicadas (Nitro Cards), deixando um hipervisor extremamente leve apenas para o isolamento de CPU e memória.

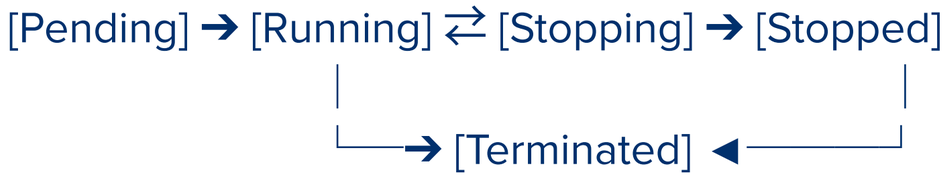
AMI (AMAZON MACHINE IMAGE):

- Uma AMI é um template que contém a configuração de software necessária para inicializar uma instância EC2: sistema operacional, servidor de aplicação e aplicações instaladas.



CICLO DE VIDA DA INSTÂNCIA

- Uma instância EC2 transita por diferentes estados entre o lançamento e o término:
  - **Pending:** A instância está sendo preparada para entrar em execução (alocação de recursos, cópia da AMI para o dispositivo raiz). Ocorre no lançamento ou ao reiniciar (start) uma instância parada.
  - **Running:** A instância está em execução e pronta para uso.
  - **Stopping:** A instância está sendo preparada para ser parada.
  - **Stopped:** A instância está desligada; pode ser iniciada (start) a qualquer momento.
  - **Shutting-down:** A instância está sendo preparada para terminação.
  - **Terminated:** A instância foi excluída permanentemente; não pode ser reiniciada.



SSH E SESSION MANAGER

SSH (Secure Shell):

- É o método tradicional de acesso a instâncias Linux.
- Ao criar o par de chaves, a chave pública fica armazenada na AWS e é injetada em ~/.ssh/authorized_keys na instância; a chave privada (arquivo .pem) fica com o usuário, a AWS não guarda cópia dela.
- Conexão típica: ssh -i minha-chave.pem .
- Exige abrir a porta 22 no security group e gerenciar as chaves privadas com cuidado.

Session Manager:

- Recurso totalmente gerenciado do AWS Systems Manager que permite gerenciar instâncias sem abrir portas de entrada, sem manter bastion hosts e sem gerenciar chaves SSH.
- O acesso é controlado inteiramente por políticas IAM, o que centraliza a concessão/revogação de permissões.
- As sessões podem ser registradas no Amazon S3 e/ou no CloudWatch Logs, favorecendo auditoria e conformidade.
- Requer o agente SSM instalado e em execução na instância e um perfil de instância (IAM instance profile) com as permissões necessárias.
- Elimina a necessidade de deixar a porta 22 (ou 3389, no caso de RDP) aberta para a internet.

GRUPOS DE SEGURANÇA

- Funciona como um firewall virtual que controla o tráfego de entrada e saída associado a uma instância (ou outro recurso de rede).
- **Security groups** operam no nível da instância e são stateful (armazena informações sobre o contexto e o histórico de interações de uma sessão de usuário);
- **Network ACLs (NACLs)** (firewall virtual que atua no nível da sub-rede em ambientes de nuvem) operam no nível da sub-rede e são stateless (exigem regras explícitas de entrada e saída).

GRUPOS DE SEGURANÇA

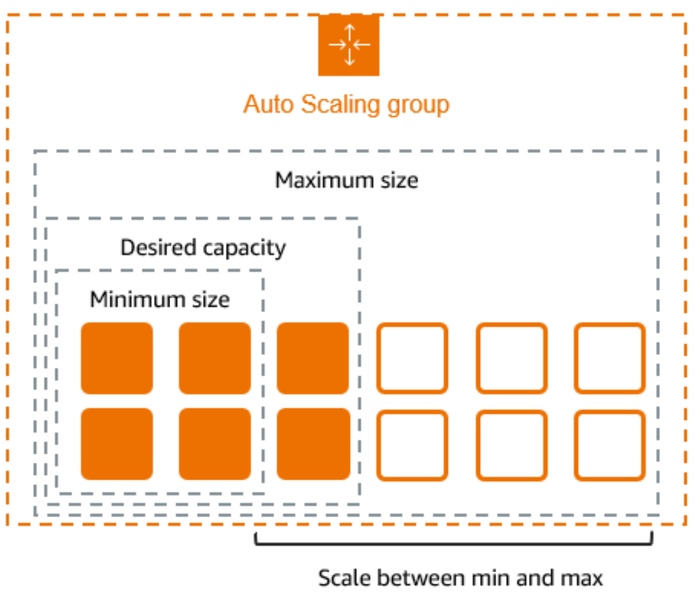
Características principais:

- **Stateful:** se o tráfego de entrada é permitido, o tráfego de resposta correspondente é automaticamente permitido de saída. Isso é feito via connection tracking: a AWS rastreia a conexão (portas, protocolo) para reconhecer que o tráfego de retorno pertence a uma conexão já estabelecida.
- **Cada regra especifica:** protocolo, intervalo de portas e origem (inbound) ou destino (outbound), podendo ser um endereço IP ou outro security group.
- Uma instância pode ter múltiplos security groups associados simultaneamente.
- Toda VPC vem com um security group padrão; por padrão ele permite todo tráfego de entrada e saída entre recursos associados a ele mesmo.

USER DATA

- Um script ou conjunto de diretivas que pode ser fornecido no momento do lançamento da instância para automatizar tarefas de configuração inicial.
- Tratado como dado opaco: a AWS não o interpreta, cabe ao sistema operacional da instância executá-lo.
- Por padrão, executa apenas uma vez, durante o primeiro boot da instância. Para executar em boots subsequentes, é necessário configurar isso explicitamente.
- Casos de uso comuns: instalar pacotes e atualizações, subir serviços, configurar variáveis de ambiente, registrar a instância em um serviço externo. Tudo isso automatiza o provisionamento e reduz o tempo até a instância ficar pronta para produção.

AUTO SCALING



- As instâncias são organizadas em um Auto Scaling Group (ASG).
- O ASG garante que o número de instâncias em execução esteja de acordo com a demanda, lançando ou terminando instâncias automaticamente.
- As ações de escala podem ser disparadas por: métricas do Amazon CloudWatch (ex.: uso médio de CPU acima de 80% ➜ scale out; abaixo de 30% ➜ scale in), agendamento (scheduled scaling) ou políticas de rastreamento de alvo (target tracking).
- Frequentemente combinado com um Elastic Load Balancer (ELB), que distribui as requisições entre as instâncias do grupo e redireciona o tráfego para instâncias saudáveis em caso de falha.
- O ASG pode abranger múltiplas Availability Zones (AZs) dentro de uma Região, o que também contribui para alta disponibilidade — a aplicação sobrevive à perda de uma AZ inteira.

RELAÇÃO ENTRE CAPACIDADE E CUSTO

- **On-Demand:** Pagamento por segundo ou hora de uso, sem compromisso de longo prazo. Maior custo relativo, ideal para cargas de trabalho imprevisíveis.
- **Reserved Instances:** Compromisso de uso contínuo por 1 ou 3 anos em troca de descontos significativos (até ~72%).
- **Spot Instances:** Uso de capacidade ociosa da AWS vendida com até 90% de desconto. Podem ser interrompidas pela AWS com um aviso prévio de 2 minutos caso a capacidade seja necessária. Indicadas para processamento tolerante a falhas e computação em lote.
- **Dedicated Hosts:** Servidores físicos totalmente dedicados ao cliente, utilizados para atender a requisitos de conformidade ou licenças de software restritivas.

AMAZON EBS

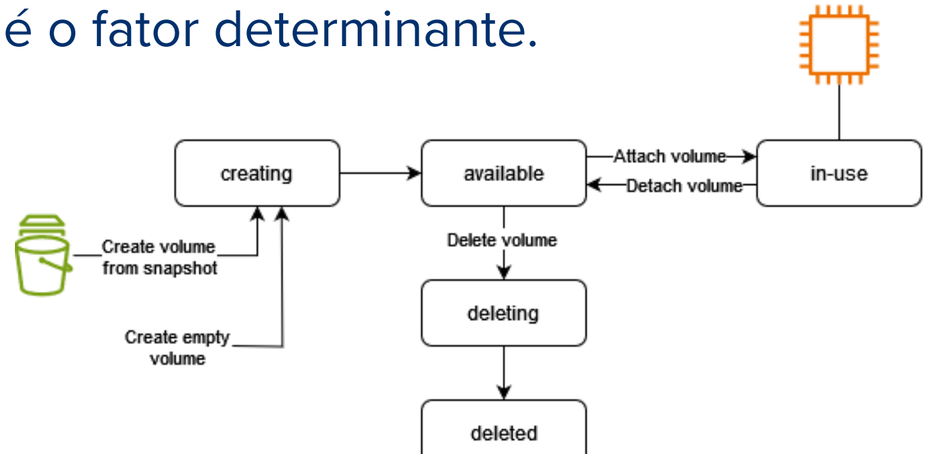
O Amazon EBS fornece armazenamento em bloco persistente, projetado para ser usado com instâncias Amazon EC2. Funciona como um disco rígido virtual que pode ser anexado a uma instância.

Volumes:

- Unidade de armazenamento em nível de bloco. Diferentemente do armazenamento de instância, que é físico e temporário no próprio host, o EBS é um serviço de rede, os dados residem fora da instância.
- Cada volume é replicado dentro de sua própria Availability Zone para proteção contra falha de componente.
- Por padrão, um volume só pode ser anexado a uma instância por vez.
- É possível monitorar volumes via métricas do Amazon CloudWatch sem custo adicional.

TIPOS DE VOLUME

- **SSD (gp2 / gp3):** Cargas de trabalho gerais, volumes raiz, ambientes de desenvolvimento/teste, bancos de dados de porte médio. gp3 permite provisionar IOPS e throughput independentemente do tamanho.
- **SSD (io1 / io2):** Aplicações que exigem alta taxa de IOPS mantida sustentadamente e baixa latência (ex: bancos de dados SQL de grande escala).
- **HDD (st1):** Cargas de trabalho intensivas em armazenamento e dados de acesso frequente com grandes blocos de E/S (ex: Big Data, Data Warehouses, processamento de logs).
- **HDD (sc1):** Armazenamento de dados acessados com menor frequência (cold data), onde o menor custo por GB é o fator determinante.



CAPACIDADE DE VOLUME

- **gp2 / gp3:** 1 GiB – 16.384 GiB
- **io1 / io2:** 4 GiB – 16.384 GiB
- **st1 / sc1:** 125 GiB – 16.384 GiB
- **standard:** 1 GiB – 1.024 GiB

PERSISTÊNCIA

- Os dados no EBS persistem independentemente do ciclo de vida da instância. Se a instância for interrompida, os dados permanecem intactos no volume.
- Pode ser configurado para ser mantido ou excluído automaticamente ao término da instância.

SNAPSHOTS

- Backups incrementais de volumes armazenados no Amazon S3, são gerenciados internamente pela AWS.
- O primeiro snapshot copia todos os dados do volume. Snapshots subsequentes salvam apenas os blocos alterados desde o último snapshot.
- Embora o volume pertença a uma AZ, os snapshots pertencem à Região, permitindo restaurar o volume em qualquer AZ daquela região ou copiá-lo para outras regiões da AWS.
- Podem ser usados para criar AMIs personalizadas.

ASSOCIAÇÃO COM EC2

- Um volume EBS é conectado a uma instância por meio da operação de anexação, que o disponibiliza como um dispositivo de bloco dentro do sistema operacional da instância.
- O volume raiz é anexado automaticamente no momento do lançamento e contém o sistema operacional.
- É possível anexar volumes adicionais a uma instância em execução, bem como desanexar e reanexar a outra instância. O que possibilita, por exemplo, mover dados entre instâncias ou recuperar dados de uma instância com problema.
- Um volume convencional só pode estar anexado a uma instância por vez; a exceção é o recurso Multi-Attach, disponível para volumes io1/io2, que permite compartilhar um mesmo volume entre até 16 instâncias baseadas em Nitro (uso típico: clusters de aplicações com sistema de arquivos com reconhecimento de concorrência).
- Essa flexibilidade de anexar/desanexar é o que permite tratar o armazenamento como um recurso desacoplado do ciclo de vida computacional.

IMPACTO DE I/O E CUSTO

- Em uma instância comum (não otimizada), o tráfego entre a instância e o volume EBS compartilha a mesma interface de rede usada pelo tráfego geral da aplicação podendo gerar contenção.
- Instâncias EBS-optimized fornecem banda dedicada entre a instância EC2 e os volumes EBS, minimizando a disputa entre o tráfego de I/O do EBS e o tráfego de rede da aplicação.
- A performance efetiva de I/O é limitada pelo menor entre três fatores: (1) o limite de performance do próprio volume (IOPS/throughput conforme o tipo), (2) a banda dedicada ao EBS da instância escolhida, e (3) o tamanho do I/O da carga de trabalho. Por isso a AWS recomenda escolher um tipo de instância cuja banda dedicada ao EBS seja maior do que a necessidade real da aplicação, evitando que a conexão EC2↔EBS vire o gargalo.

IMPACTO DE I/O E CUSTO

- **Armazenamento provisionado:** cobrado por GB-mês, independentemente de o espaço estar de fato ocupado por dados (paga-se pelo que é provisionado, não pelo que é usado).
- **Performance provisionada:** em volumes gp3, io1 e io2, IOPS e throughput acima do baseline incluído são cobrados separadamente (por IOPS-mês e por MB/s-mês provisionados).
- **Armazenamento de snapshots:** cobrado por GB-mês de dados armazenados nos snapshots (que, como são incrementais, tendem a custar menos do que uma cópia completa a cada backup).

GERENCIAMENTO E AUTOMAÇÃO DE INFRAESTRUTURA NA AWS

- EC2 AUTO SCALING
- AWS SYSTEMS MANAGER
- AWS CLOUDFORMATION

GERENCIAMENTO E AUTOMAÇÃO DE INFRAESTRUTURA NA AWS

SERVIÇOS ESSENCIAIS



EC2 AUTO SCALING

POR QUE USAR EC2 AUTO SCALING?

- Picos de acesso
- Falha de Instâncias
- Capacidade ociosa e custos desnecessários

EC2 AUTO SCALING



EC2 AUTO SCALING

LAUNCH TEMPLATE

- AMI
- Tipo da Instância
- Security Group
- Key Pair
- outras configurações

COMO CRIAR?

AUTO SCALING GROUP

- gerencia o conjunto de EC2
- Mantém a capacidade
- Pode aumentar ou diminuir o grupo
- Pode distribuir instâncias entre Availability zones

QUANTAS MANTER?

EC2 AUTO SCALING

MIN

Nunca menos

DESIRED

Quantas eu quero agora

MAX

Nunca mais

EX:

Min = 2
Desired = 3
Max = 6

EC2 AUTO SCALING

SCALING POLICIES

TARGET TRACKING

Procura manter uma métrica próxima de um alvo

Por exemplo: manter a cpu em 50%

EC2 AUTO SCALING

SCALING POLICIES

STEP SCALING

Reage com diferentes ajustes, conforme a métrica

Por exemplo:

Cpu > 50% → Mais 2 EC2
Cpu > 65% → Mais 3 EC2
Cpu > 75% → Mais 4 EC2

EC2 AUTO SCALING

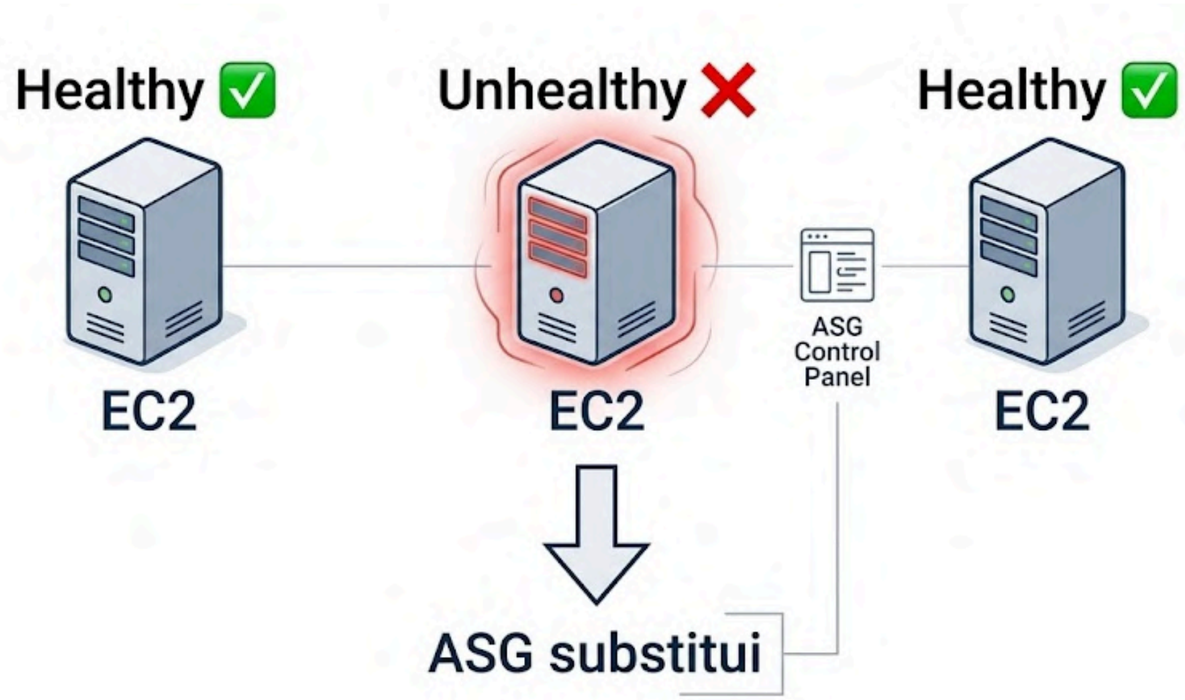
CLOUDWATCH

É justamente o que observa e fornece as métricas usadas nas **Scaling Policies**

EC2 AUTO SCALING

HEALTH CHECKS

É o jeito que o Auto Scaling Group consegue perceber se uma EC2 é **healthy** ou **não**



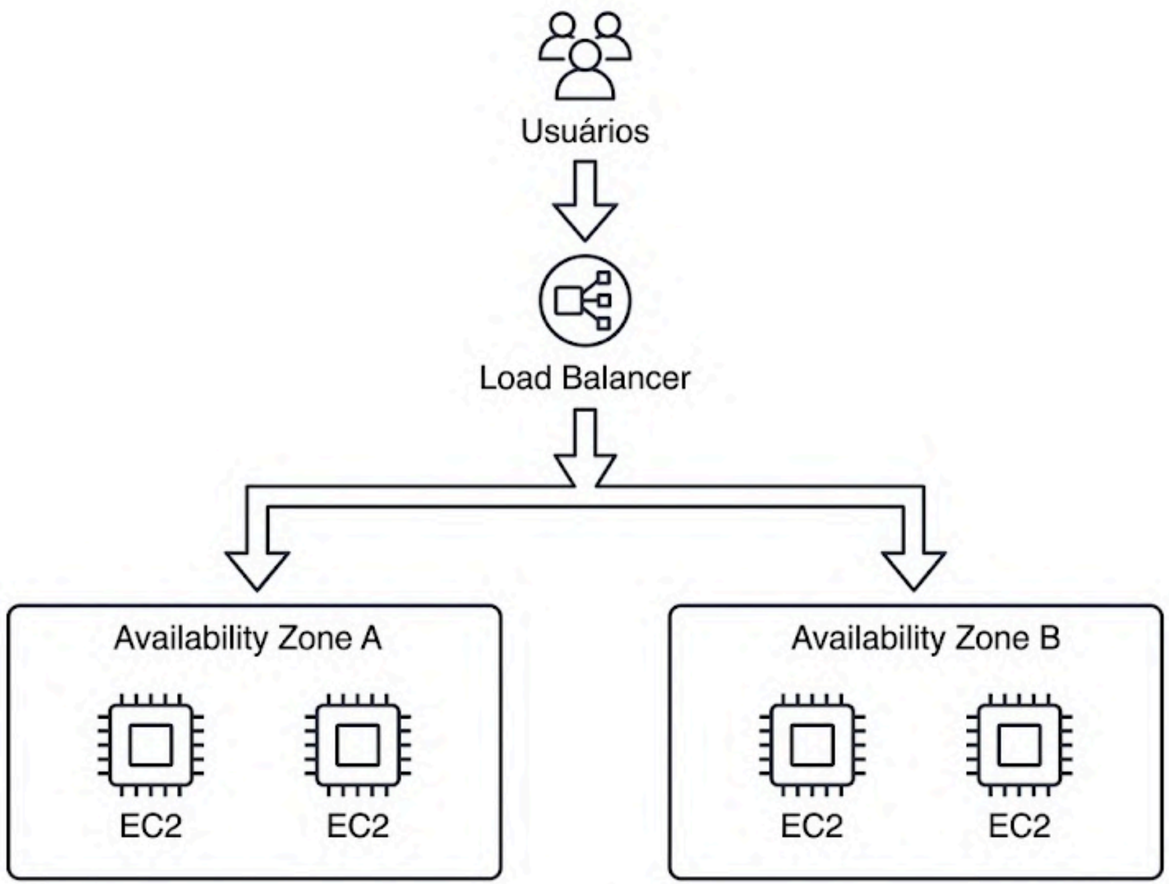
EC2 AUTO SCALING

HEALTH CHECKS

- Instance status check
- System status check
- Elastic Load Balancer health checks

EC2 AUTO SCALING

ELASTIC LOAD BALANCER



EC2 AUTO SCALING

ELASTIC LOAD BALANCER

- Distribui as requisições entre as EC2 saudáveis.
- Pode ser integrado ao Auto Scaling Group.
- Novas EC2 criadas pelo ASG podem ser registradas automaticamente.
- EC2 removidas pelo ASG deixam de receber tráfego.

EC2 AUTO SCALING

ELASTIC LOAD BALANCER

Contribui para alta disponibilidade

Se há algum problema envolvendo uma Availability Zone, a aplicação continua disponível por meio das EC2 em outras AZs

EC2 AUTO SCALING

ELB

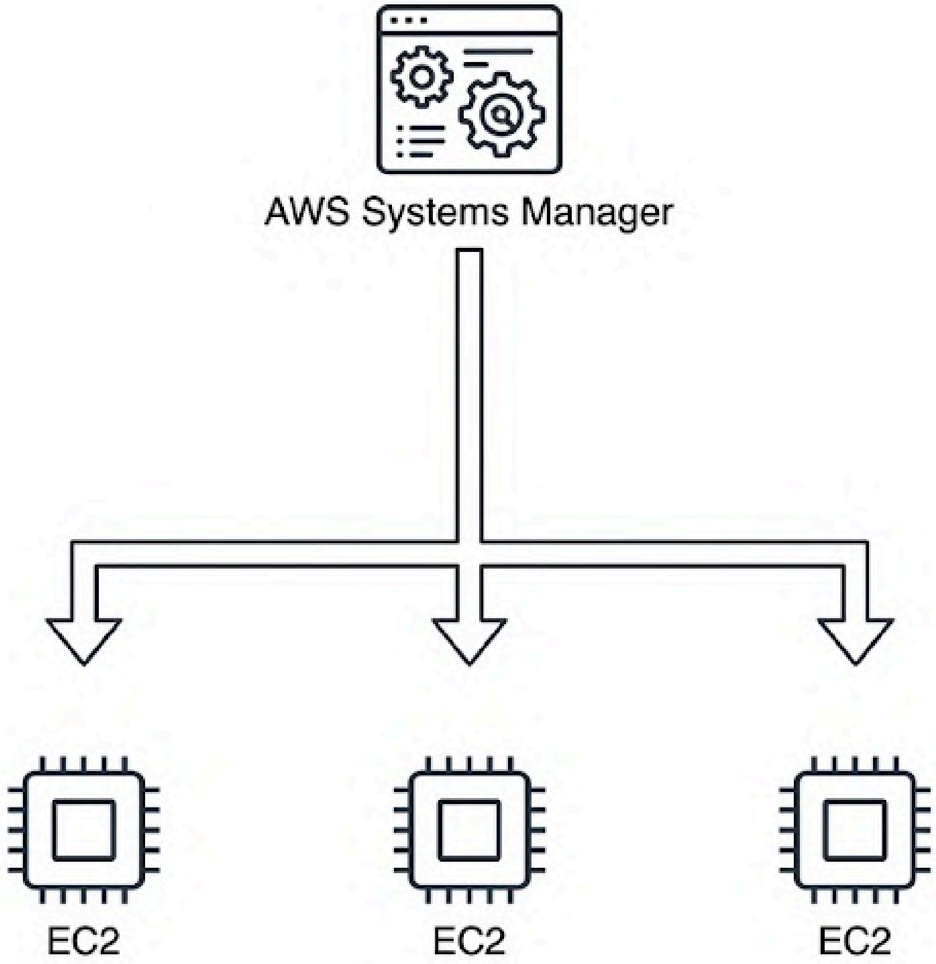
Distribui o Tráfego

AUTO SCALING

Gerencia a capacidade

AWS SYSTEMS MANAGER

ADMINISTRAÇÃO CENTRALIZADA DE MANAGED NODES



AWS SYSTEMS MANAGER

ADMINISTRAÇÃO CENTRALIZADA DE MANAGED NODES

Gerenciamento centralizado

SSM Agent para comunicação com os nós

Controle de Acesso por IAM

AWS SYSTEMS MANAGER

SESSION MANAGER

- Acesso Interativo
- Abre um terminal
- Ideal para investigar uma máquina
- Não exige expor SSH tradicional

RUN COMMAND

- Execução remota
- Envia uma ação
- Ideal para agir em várias máquinas
- Não exige entrar em cada máquina
- SSM Documents

AWS SYSTEMS MANAGER

INVENTORY

- Coleta informações periodicamente
- Aplicações instaladas
- Configurações
- Informações do sistema

IAM

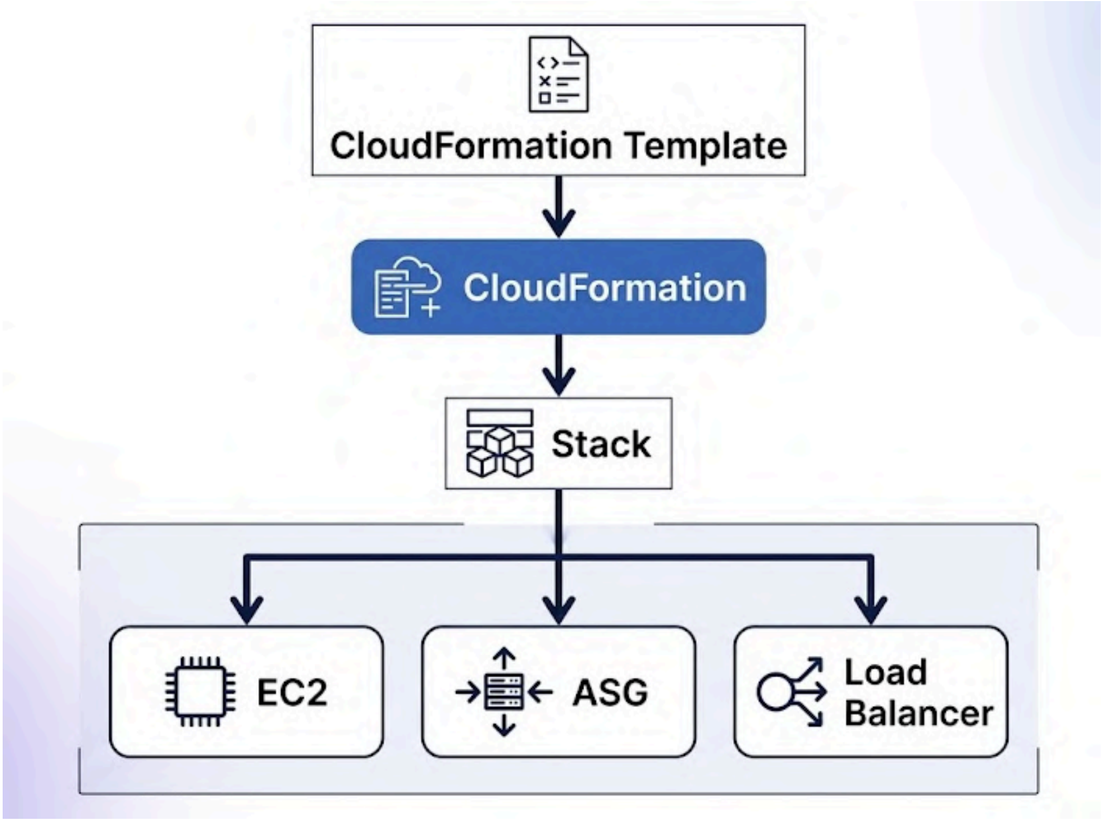
- Valida quem pode iniciar Sessão
- Quem pode usar Run Command
- Em quais recursos
- Permissões para instâncias

  operarem como managed nodes

CLOUDFORMATION

INFRAESTRUTURA COMO CÓDIGO

A infraestrutura é descrita em **templates** YAML ou JSON



O template pode criar

- Launch Templates
- Auto Scaling Group
- Load Balancer

CLOUDFORMATION

INFRAESTRUTURA COMO CÓDIGO

LAUNCH TEMPLATE

Descreve como lançar uma EC2

CLOUDFORMATION TEMPLATE

Descreve a Infraestrutura

CLOUDFORMATION

STACK E INFRAESTRUTURA REPRODUZÍVEL

PARAMETERS

Entradas

RESOURCES

Recursos criados

OUTPUTS

Informações de Saída

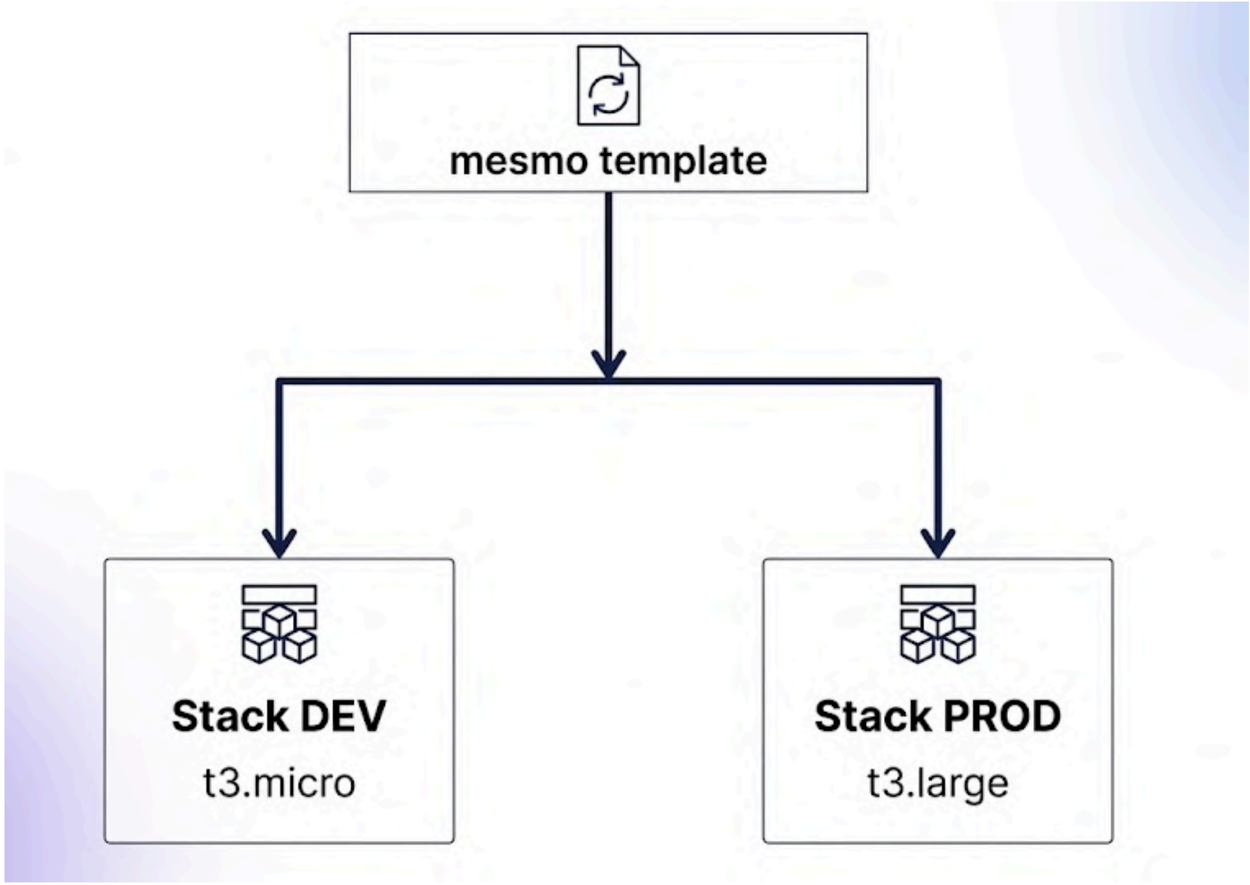
```yaml
Parameters:
  TipoInstancia:
    Type: String
    Default: t3.micro

Resources:
  MinhaEC2:
    Type: AWS::EC2::Instance
    Properties:
      InstanceType: !Ref TipoInstancia
      ImageId: ami-1234567890abcdef0

Outputs:
  IdDaInstancia:
    Value: !Ref MinhaEC2
```

CLOUDFORMATION

STACK E INFRAESTRUTURA REPRODUZÍVEL



CLOUDFORMATION

STACK E INFRAESTRUTURA REPRODUZÍVEL

UPDATE

Adapta a stack às mudanças do template

DELETE

Gerencia a remoção da stack e dos recursos aplicáveis, respeitando as políticas configuradas

A infraestrutura pode ser recriada de forma padronizada, reproduzível e versionável

OBRIGADO!